


Mini Project AI

Data Scrapping


Presented by:

Silvia Zahro



Mini Project AI


API yang Dipakai



API: Google Books API

Alasan memilih:

- Gratis dan API key mudah didapat (lewat Google Cloud Console)
- Dokumentasi jelas dan lengkap
- Data yang tersedia kaya (judul, penulis, penerbit, tanggal terbit, rating, kategori, dll) — cocok buat latihan cleaning data
- Tidak butuh proses approval manual yang lama




Class yang Dibangun

Atribut:

- `api_key` — menyimpan API key dari file `.env`
- `base_url` — menyimpan alamat endpoint Google Books API

Method:

- `get_books(query, max_results, start_index)` — memanggil API berdasarkan kata kunci pencarian, mengembalikan data buku dalam bentuk list of dict, dibungkus try-except supaya program tidak berhenti total kalau koneksi bermasalah




Mini Project AI

Cuplikan Dataset


```
df.shape  
✓ 0.0s  
(160, 8)
```

	title	authors	publisher	published_date	page_count	categories	average_rating	language
0	The Art of Fiction	Walter Besant	GRIN Verlag	1885-01-01	106	Fiction	4.083333	en
1	A Library of Famous Fiction	Nathaniel Hawthorne	GRIN Verlag	1873-01-01	1084	English fiction	4.083333	en
2	Into The Mind : Introduction to Prose Fiction	Dr. Sony Sukmawan, M.Pd dan Dr. Lestari Setyow...	Media Nusa Creative (MNC Publishing)	1895-01-01	173	Education	4.083333	id
3	A Century of French Fiction	Benjamin Willis Wells	GRIN Verlag	1898-01-01	418	French fiction	4.083333	en
4	Desire and Domestic Fiction	Nancy Armstrong	Oxford University Press	1895-01-01	318	Language Arts & Disciplines	5.000000	en
5	Love and Sexuality in Dystopian Fiction. An An...	Lena Gräf	GRIN Verlag	1895-01-01	24	Literary Criticism	4.083333	en
6	A History of English Prose Fiction from Sir Th...	Bayard Tuckerman	GRIN Verlag	1882-01-01	354	English fiction	4.083333	en
7	Author and Title List of Fiction and Children'...	Nahant Public Library, Nahant, Mass	GRIN Verlag	1895-01-01	168	Fiction	4.083333	en
8	Fan Fiction and Fan Communities in the Age of ...	Karen Hellekson, Kristina Busse	McFarland	1895-01-01	297	Literary Criticism	4.083333	en
9	English Prose Fiction in the Free Public Libra...	Newark Public Library	GRIN Verlag	1900-01-01	136	English fiction	4.083333	en



Keputusan Pembersihan Data

Kolom	Keputusan	Alasan
title	Baris dibuang jika kosong	Judul adalah identitas utama buku; tanpa itu data tidak berguna
authors	Diisi "Tidak diketahui"	Penulis adalah identitas unik per buku; tidak valid ditebak pakai modus
publisher	Diisi "Tidak diketahui"	Sama seperti authors, sangat spesifik per buku
categories	Diisi "Tidak diketahui"	Kategori spesifik per buku, tidak bisa digeneralisasi dari buku lain
language	Diisi modus (nilai tersering)	Ada pola dominan bahasa dalam dataset, estimasi ini masuk akal
page_count	Diisi rata-rata (mean)	Kolom angka; mean adalah estimasi statistik yang wajar
average_rating	Diisi rata-rata (mean)	Kolom angka; sama seperti page_count
published_date	Diisi median	Median lebih tahan outlier dibanding mean untuk data tanggal
Data duplikat	Dibuang (title + authors sama)	Buku sama bisa muncul 2x karena kata kunci pencarian berbeda
Tipe data	int / float / datetime	Supaya page_count, average_rating, published_date bisa diproses sebagai angka/tanggal, bukan teks



Mini Project AI

Thank You

Website:

www.github.com/silviaazahro